

강 18

RLHF (인간 피드백 강화학습)

AI Prompt Engineer · ISO/IEC 17024 — 필기 대비

*RLHF의 3단계와 GPT 응답
개선에서의 역할을 설명한다.*





핵심 정리

- **정의**: 강화학습의 한 종류로 **인간 피드백**을 학습에 추가 → LLM을 '예측기'에서 '인간 가치를 이해하는 비서'로 진화.
- **3단계(암기)**:
- **결정적 역할**: 안전성·윤리(유해 답변 억제), 미묘한 맥락 파악, **환각 제어**, 창의·유용성 품질↑ → '인간 중심 AI'.



예상문제

- 예상문제(4지선다): RLHF 2단계에서 만드는 것은? ①SFT 모델 ②보상 모델 ③토큰나이저 ④임베딩 → ②.