

강 19

딥페이크와 AI 윤리·필터링

AI Prompt Engineer · ISO/IEC 17024 — 필기 대비

딥페이크 원리·양면성과 AI 윤리/필터링 방안을 설명한다.



핵심 정리

- **딥페이크(Deepfake)**: Deep Learning + Fake. **GAN(생성적 적대 신경망)** 기반으로 얼굴·음성을 조작·합성.
 - **GAN 작동**: 생성자(Generator)(위조지폐범) vs 판별자(Discriminator)(경찰)가 경쟁 학습 → 점점 정교한 가짜.
 - 인코더-디코더로 한 인물 특징을 다른 영상에 합성.
- **유익 사례**: 영화 배우 복원, 역사 인물 가상 강연, 다국어 더빙(립싱크), 박물관 VR 가이드.
- **무익/위험**: 가짜뉴스·정치 선동, 보이스피싱, 디지털 성범죄·명예훼손 → **사회적 신뢰 붕괴**.
- **AI 윤리·필터링(PART13)**: ①데이터 필터링(유해·민감정보 제거) ②RLHF(인간 가치 내재화) ③Human-in-the-loop 모니터링 ④적대적 훈련/**레드팀**(취약점 공격) ⑤배포 전 윤리 검토·배포 후 감사.



예상문제

- 예상문제(4지선다): 딥페이크의 기반 기술은? ①RNN ②GAN ③NER ④RLHF → ②.