

강 28

AI 윤리·안전 실무

AI Prompt Engineer · ISO/IEC 17024 — 2차 실기 대비 (윤리)

"강력한 도구일수록 책임이 따른다."





학습 목표

1. 4대 윤리 리스크 를 안다
2. 각 리스크의 실무 대응 을 익힌다
3. 안전한 프롬프트 운영 원칙 을 적용한다



도입 — 잘 쓰기 위한 안전장치

- AI는 강력하지만 위험도 함께 커짐
- 프롬프트 엔지니어는 **안전 책임** 도 진다
- 4대 리스크: 할루시네이션·편향·개인정보·딥페이크



리스크 ① 할루시네이션

- 없는 사실을 그럴듯하게 생성
- **대응:** 근거 제공(RAG), "모르면 모른다", 출처 검증
- 중요한 정보는 **사람이 확인**



리스크 ② 편향(Bias)

- 학습 데이터의 차별을 재생산
- **대응:** 독립적 표현, 다양성 점검, 결과 감사
- 민감 속성(성별·인종 등) 주의



리스크 ③ 개인정보

- 프롬프트에 민감정보 입력 위험
- **대응:** 익명화·가명화, 민감정보 미입력
- 사내 정책·법규(개인정보보호법) 준수



리스크 ④ 딥페이크·악용

- 생성물 악용(가짜·사칭)
- **대응:** 출처·워터마크 표시, 용도 제한
- 생성 콘텐츠임을 **명시**



안전 프롬프트 운영 원칙

- 투명성: AI 사용·한계 고지
- 검증: 사실·출처 확인 절차
- 인간 감독: 최종 판단은 사람
- 최소 정보: 필요한 데이터만



실무 체크리스트

- [] 근거/출처를 확인했는가?
- [] 편향·차별 표현은 없는가?
- [] 개인정보를 넣지 않았는가?
- [] 생성물임을 표시했는가?



흔한 오해 (시험 주의)

- "AI 답은 항상 사실이다" → ✗ (검증 필요)
- "프롬프트에 개인정보 넣어도 안전" → ✗ (위험)



정리 & 예상문제(실기)

- 4대 리스크(할루시네이션·편향·개인정보·딥페이크)+대응
 1. (주관식) AI의 4대 윤리 리스크를 쓰시오.
 2. (실기) 개인정보가 포함된 프롬프트를 안전하게 수정하시오.